


A



P  
E  
A  
S

Performance

Estado S

Entorno

$$S = (S_1, S_2, \dots, S_n) \in D_1 \times D_2 \times \dots \times D_n$$


Actuadores

↓ esto significa

Sensores

Mi espacio es un vector con diferentes valores que pertenecen a diferentes dominios.

Ejemplo de espacio estado (Pac-man)



$$S = (f, c, i_0, \dots, i_{\text{num}-1})$$

$$i_k = \text{indicador si hay punto en la posición } f = k \div m$$


$$c = k \mod m$$

$$f \in \{0, 1, \dots, n-1\}$$

$$c \in \{0, 1, \dots, m-1\}$$

$$i_k \in \{0, 1\} \quad \forall k = 0, \dots, \text{num}-1$$


Actividad en clase (Juegos)



$$S = [i_{11}, \dots, i_{15}, i_{21}, \dots, i_{25}, i_{31}, \dots, i_{35}]$$

$$i_{a,b} \in \{0, 1\}$$

$$|S| = 2^{15} = 32 \times 10^3$$



$$S = [E, O, L]$$

$$E = \{0, 1, 2, 3\}$$

$$O = \{0, 1, 2, 3\}$$

$$L = \{0, 1\}$$

$$S = [S_1, \dots, S_5]$$

$$S_i \in \{A, B, C\}$$

$$|S| = 3^5 = 243$$

$$|S| = 4 \times 4 \times 2 = 32$$

Tipos de estados (características)

Determinista, Estático, Observable, Discreto

$$S = f(a)$$

↑ estado      ↓ acción

P Podemos tener..

$a \in A$  + conjunto de acciones

O también...

$a \in A(S)$  acciones legales en  $S$

Determinista, Dinámico, Observable, Discreto

$$S_{k+1} = f(S_k, A_k)$$

Determinista, Dinámico, Parcialmente observable, Discreto

$$S_{k+1} = f(S_k, A_k)$$

$$P_k = g(S_k)$$

Espacio continuo:

$$x_t = f(x_t, a_t)$$

$$P_t = g(x_t)$$

Cuando se tiene un problema donde no hay certeza de lo que va a pasar es estocástico...

Estocástico, Discreto, Estático

$$Pr[S/a] = \begin{bmatrix} Pr[S=s^{[1]}|a] \\ \vdots \\ Pr[S=s^{[n]}|a] \end{bmatrix}$$


A

Estocástico, Discreto, Dinámico


$$\Pr[S_{k+1} | s_k, a_k] = \left[ \begin{array}{l} \Pr[S_{k+1} = s^{(1)} | s_k, a_k] \\ \vdots \\ \Pr[S_{k+1} = s^{(n)} | s_k, a_k] \end{array} \right]$$

$$-\min(-a, -b) = \max(a, b)$$

Ejemplo:




## Intelligent Agents



Agente incluye humanos, robots, etc.

Ejemplo: Aspiradora



- Percepciones: Ubicación y contenidos
- Acciones: Izquierda, derecha, aspira y an-operar

$$S = (A, B, R)$$

$$A \in \{L, S\}$$

$$B \in \{L, S\}$$

$$R \in \{A, B\}$$

$$A = \{\leftarrow, \rightarrow, \text{aspira}, \text{nada}\}$$

acciones

percepciones

$$P = (R, S[R])$$

Secuencia de percepción

A, Limpio

A, Sucio

B, Limpio

B, Sucio

[A, Limpio], [A, Limpio]

[A, Limpio], [A, Sucio]

:


Acción

Derecha


Aspira

Izquierda

Aspira



A



Esto ayudo para resolver problemas en sistemas reactivos con estados.

¿Qué se necesita para crear un entorno?

### Entorno

$S =$  Estado

$S = (S_1, \dots, S_n) \in D_1 \times \dots \times D_n = S$

$a_t \in A = \{a_1, \dots, a_m\}$

$a_t \in A (S_t) \rightarrow$  acciones legales

$p_t \in P \longleftrightarrow$  espacio de percepciones.


$p_t =$  percepción ( $S_t$ )

percepción:  $S \rightarrow P$

$S_{t+1} =$  transición ( $S_t, a_t$ )

costo ( $S_t, a_t, S_{t+1}$ )

Sistema entorno de agente




El agente recibe percepciones y retorna acciones.

[En python se puede usar "\_" para variables anónimas]

Agente reactivo

$f_A$  es desconocida

$f_A: X \rightarrow Y \quad --- \quad Y$  es el espacio de salida



tipicamente  $X = \mathbb{R}^n$

$x = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$

Si  $y = \mathbb{R}$  --- Regresión.

Si  $y = \{-1, 1\}$  -- Clasificación Binaria.

Si  $y = \{C_1, C_2, \dots, C_K\}$  Clasificación en varias clases.

$\{x^{(1)}, x^{(2)}, \dots, x^{(m)}\}$  una muestra de  $X$  de dist. desconocida

$$\mathcal{D} = \{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})\}$$

donde  $y^{(i)} = f_A(x^{(i)}) + \epsilon$  v.a. dist. desconocida

El problema es encontrar una función  $h^*: X \rightarrow Y$   
tal que  $h^* \approx f_A$

$h^* \in H$  hipótesis posibles

$$H = \{h_\alpha \mid h_\alpha: \mathbb{R} \rightarrow \mathbb{R} \text{ donde } h_\alpha(x) = \alpha x, \forall \alpha \in \mathbb{R}\}$$

$$X = [x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_8, x_9, x_{10}, x_{11}, x_{12}]$$

$$\begin{bmatrix} x^{(1)} & \cdots & x_R^{(1)} \\ x^{(2)} & \cdots & x_R^{(2)} \\ \vdots & & \vdots \\ x^{(m)} & \cdots & x_R^{(m)} \end{bmatrix} \begin{bmatrix} \\ \\ \\ \end{bmatrix} \quad \begin{matrix} x \\ Y \end{matrix}$$

A

$$h: X \times H \rightarrow Y$$

$$\text{parámetros: } h(x^{(i)}, \theta) = \hat{y}^{(i)}$$

o también se puede escribir como (es equivalente):

$$h_{\theta}(x^{(i)}) = \hat{y}^{(i)}$$

Si  $\theta$  es un vector de parámetros fijo

$$h_{\theta}: X \rightarrow Y$$


Ejemplo:

$$h_w(x) = \sum_{j=1}^T w_j x^j + w_0, \quad x^j \in \mathbb{R}$$


$$h_w: \mathbb{R} \rightarrow \mathbb{R}$$

$$w = (w_0, w_1, \dots, w_T) \in \mathbb{R}^{T+1}$$

$$\hat{y} = w_1 x + w_0, \quad \hat{y} = w_2 x^2 + w_1 x + b$$



Ejemplo:




El 2 es el mejor ya que se aproxima lo más posible a todos los puntos sin ser muy complejo, como el 3 que aunque toque exactamente todos los puntos es demasiado complejo.

$$\Theta = \emptyset$$

## Hipótesis

- 1..  $f: X \rightarrow Y$  existe y es desconocida.
- 2.. Tengo  $\{x^{(1)}, \dots, x^{(m)}\} \subseteq X$  una muestra de m datos con distribución desconocida.
- 3..  $D = \{(x^{(i)}, y^{(i)})_i, \dots, (x^{(m)}, y^{(m)})\}$ , donde  $y^{(i)} = f(x^{(i)}) + e^{(i)}$  donde  $e^{(i)}$  son VA
- 4.. Tenemos una función "parametrizada"  $h: X \times \Theta \rightarrow Y$ , típicamente  $\Theta = \mathbb{R}^p$
- 5.. Para un valor específico de  $\Theta$ ,  $h_\theta: X \rightarrow Y$
- 6..  $h_\theta \in \mathcal{H}$  conjunto de hipótesis
- 7.. El aprendizaje supervisado consiste en encontrar  $h^* \in \mathcal{H}$  tal que

$$h^* \approx f$$



$L: Y \times Y \rightarrow \mathbb{R}$  función de perdida

$$L(y, \hat{y}) = L(f(x), h^*(x))$$

$$L(y, \hat{y}) = \begin{cases} \frac{1}{2}(y - \hat{y})^2 & y \in \mathbb{R}, \\ |y - \hat{y}| & \end{cases}$$

$$\frac{|y - \hat{y}|}{y}$$

$$L(y, \hat{y}) = \begin{cases} 0 & \text{si } y = \hat{y} \\ 1 & \text{si } y \neq \hat{y} \end{cases} \Rightarrow \{y \neq \hat{y}\} \quad y \in \{-1, 1\}$$

$$E_{out}(h^*) = E_{x \in X} [L(f(x), h^*(x))]$$

$E_{out}$  = Es el error fuera de muestra

$f \approx h^*$  si y solo si  $E_{out}(h^*) \approx 0$

$$E_{in}(h^*) = \frac{1}{M} \sum_{i=1}^M L(y^{(i)}, h(x^{(i)}))$$

$E_{in}$  = Es el error en muestra

$f \approx h^*$  si  $E_{in}(h^*) \approx 0$

$$E_{in}(h^*) \approx E_{out}(h^*)$$

Nota:  $\Theta$  es un vector de parámetros, ej:

$$h_\theta(x) = w_1 x_1 + w_2 x_2 + w_3 x_1 x_2 + b \quad \Theta = (w_1, w_2, w_3, b) \in \mathbb{R}^4$$

## Desigualdad de Hoeffding (PAC-Learning)

$$P_\sigma(|E_{out}(h^*) - E_{in}(h^*)| > \epsilon) \leq \frac{1}{2} e^{-2\epsilon^2 M}$$

donde  $M$  es el tamaño de la muestra

$d_{VC}(H) \approx \# \text{parámetros INDEPENDIENTES}$

EL APRENDIZAJE ES POSIBLE SI

$$10 * d_{VC}(H) \ll M \Leftrightarrow E_{in}(h^*) \approx E_{out}(h^*)$$

$$\begin{array}{c} X^{(1)\top} \xrightarrow{\alpha_1} (X_1^{(1)}, X_2^{(1)}, \dots, X_n^{(1)}) \\ X^{(2)\top} \xrightarrow{\alpha_2} (X_1^{(2)}, X_2^{(2)}, \dots, X_n^{(2)}) \\ \vdots \\ X^{(m)\top} \xrightarrow{\alpha_m} (X_1^{(m)}, X_2^{(m)}, \dots, X_n^{(m)}) \end{array} \left[ \begin{array}{c} Y \\ y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{array} \right] \quad \begin{array}{l} X^{(i)} \in \mathbb{R}^n \\ y^{(i)} \in \mathbb{R} \end{array}$$

Instancias  $(m, n)$   $Y$   $(m, 1)$

$$D = \{(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})\}$$

conjunto de aprendizaje

$$h_\theta(x) = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + b = \sum_{j=1}^n w_j x_j + b = w^\top x + b$$

$$= x^\top w + b$$

$$\Theta = (w_1, \dots, w_n, b) \in \mathbb{R}^{n+1}$$

$$\begin{aligned} \text{Si } x &= (x_1, \dots, x_n) \in \mathbb{R}^n \\ w &= (w_1, \dots, w_n) \in \mathbb{R}^n \end{aligned}$$

Aprendizaje:

$$E_{in}(h^*) \approx E_{out}(h^*)$$

$$E_{in}(h^*) \approx 0$$

$$h^* = \arg \min_{h \in H} E_{in}(h) \Leftrightarrow \Theta^* = w^*, b^* = \arg \min_{\substack{w \in \mathbb{R}^n \\ b \in \mathbb{R}}} E_{in}(h_{w,b})$$

$$w^*, b^* = \arg \min_{\substack{w \in \mathbb{R}^n \\ b \in \mathbb{R}}} \frac{1}{M} \sum_{i=1}^m \frac{1}{2} (y^{(i)} - h_{wrb}(x^{(i)}))^2$$

MSE  
Mean Square Error

$$w^*, b^* = \arg \min_{\substack{w \in \mathbb{R}^n \\ b \in \mathbb{R}}} \frac{1}{M} \sum_{i=1}^m \frac{1}{2} (y^{(i)} - \underbrace{w^T x^{(i)} - b}_{P = X^{(i)T} w - b})^2$$

$$= \arg \min_{\substack{w \in \mathbb{R}^n \\ b \in \mathbb{R}}} \frac{1}{2M} [(y^{(1)} - x^{(1)T} w - b) \dots (y^{(m)} - x^{(m)T} w - b)]$$

$\begin{bmatrix} y^{(1)} - x^{(1)T} w - b \\ y^{(2)} - x^{(2)T} w - b \\ \vdots \\ y^{(m)} - x^{(m)T} w - b \end{bmatrix}$

$\Delta$

$$= \arg \min_{w \in \mathbb{R}^n} \frac{1}{2M} [Y - [X, 1]^T \Theta]^T [Y - [X, 1]^T \Theta]$$

$\begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix} - \begin{bmatrix} x^{(1)T} \\ x^{(2)T} \\ \vdots \\ x^{(m)T} \end{bmatrix} \Theta$

$\Delta$

$W \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} b$

Para encontrar un mínimo de una función: Se deriva y se iguala a cero →

En este caso como tenemos dos variables tenemos que derivar parcialmente, para encontrar el gradiente.

Ejemplo:  $f(x_1, \dots, x_n)$

$f(y) \quad y \in \mathbb{R}^n, f: \mathbb{R}^n \rightarrow \mathbb{R}$

$$\nabla_x f(x) = \begin{bmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{bmatrix}$$

A

Regresamos al problema...

$$[Y - X_e \Theta]^T [Y - X_e \Theta]$$

$$\frac{1}{2m} \sum_{i=1}^m [Y - X_e \Theta]$$

$$\frac{\partial (Y - Kx)^2}{\partial \Theta} = -2(Y - Kx)K$$

$$\frac{1}{m} X_e^T [Y - X_e \Theta] = \vec{0}$$

$$X_e^T Y - X_e^T X_e \Theta = \vec{0}$$

$$X_e^T X_e \Theta = X_e^T Y$$

$$\Theta \equiv [X_e^T X_e]^{-1} X_e^T Y$$

pinv( $X_e$ )

pseudo-inversa

Este es el  
método mínimo  
de cuadrados.